

機械学習プロジェクト課題レポート

学生証番号: 24RB1301

氏名: 長谷川樹

割り当てられたデータセット: B

1. 使用した最終モデル

Gradient Boosting

2. 前処理

標準化

3. モデルの選択方法

6種類のモデルに対して5分割交差検証を行い、balanced accuracyを比較し、最も高いスコアを出したモデルを選択した。

4. 比較したモデル

全てデフォルトの設定で行い、5分割交差検証を行いbalanced accuracyで比較した。

モデル	balanced accuracy
ロジスティック回帰	0.6697
線形判別分析	0.6698
ナイーブベイズ	0.7013
決定木	0.7333
ランダムフォレスト	0.8006
Gradient Boosting	0.8594

5. 最終モデルを選んだ理由

5分割交差検証でのbalanced accuracyが全モデルの中で最も高かったため。

6. 過学習を防ぐための工夫

5分割交差検証を用いてモデルを評価した。訓練データだけの性能ではなく、交差検証スコアに基づいてモデルを選択することで、未知データへの汎化性能を保てるように工夫した。

7. データの特徴についての考察

ロジスティック回帰、線形判別分析等の線形モデルのスコアが0.67前後で低く、Gradient Boostingやランダムフォレストなどのアンサンブルモデルが高い精度を示したので、データセットBの特徴量の間には非線形な関係が含まれており、決定木ベースのモデルで精度が高くなるようなデータであったと考えられる。